



(12) 发明专利申请

(10) 申请公布号 CN 120602437 A

(43) 申请公布日 2025. 09. 05

(21) 申请号 202510911065.X

(22) 申请日 2025.07.02

(71) 申请人 陕西港芯电子科技有限公司

地址 710065 陕西省西安市高新区锦业路6
号绿地领海1栋12302室

(72) 发明人 王亮 张泽

(74) 专利代理机构 西安志帆知识产权代理事务
所(普通合伙) 61258

专利代理师 成丹

(51) Int.Cl.

H04L 47/80 (2022.01)

H04L 47/2425 (2022.01)

G06F 18/214 (2023.01)

G06N 3/0442 (2023.01)

G06N 3/092 (2023.01)

权利要求书2页 说明书7页 附图7页

(54) 发明名称

一种流量特征自适应的QoS智能预测调整方
法

(57) 摘要

本发明公开了一种流量特征自适应的QoS智能预测调整方法,本发明涉及网络流量管理领域,方法包括:1.实时采集流量数据,基于协议类型、端口号及用户行为动态分类,构建多维特征向量;2.分离高频/低频分量,通过LSTM短期预测模块与周期趋势分析模块融合输出QoS参数预测;3.以最小化分组时延为目标,采用强化学习求解资源预分配方案;4.利用NPU硬件卸载执行流量识别、限速及优先级队列调度。本发明通过高频/低频联合预测架构提升精度,强化学习与NPU协同使决策时延进行较大程度的压缩,同时预测误差触发机制实现模型在线迭代。



1. 一种流量特征自适应的QoS智能预测调整方法,其特征在于,包括以下步骤:

(1) 实时采集网络数据流,根据协议、端口号、应用特征及用户行为数据对流量进行动态分类与标记,生成多维特征向量;

(2) 基于长短期预测融合模型处理所述多维特征向量:将历史QoS参数、网络状态信息及用户设备行为数据按时间序列分层,分离高频波动分量与低频趋势分量,分别输入LSTM短期预测模块和周期趋势分析模块,输出未来预设时间段内的QoS预测参数;

(3) 根据QoS预测参数构建资源优化模型,以最小化分组平均时延为目标,通过强化学习求解离散空间下的资源预分配方案,动态调整带宽分配及优先级策略;

(4) 通过硬件加速层执行资源预分配方案:利用NPU对流量识别、限速及优先级队列进行硬件卸载,实时输出QoS调整指令至网络设备。

2. 根据权利要求1所述的一种流量特征自适应的QoS智能预测调整方法,其特征在于,所述步骤(1)中的动态分类与标记包括:

提取流量数据的协议类型、源/目的端口号、数据包大小分布特征;

关联用户行为特征,包括访问频率、地理位置活跃度及历史异常行为标签;

基于对称不确定性算法筛选与QoS需求强相关的特征属性,构建自适应特征规则库。

3. 根据权利要求1所述的一种流量特征自适应的QoS智能预测调整方法,其特征在于,所述长短期预测融合模型的处理包括:

高频波动分量输入LSTM网络,学习短期突发流量特征;

低频趋势分量通过核函数岭回归模型分析周期性规律,结合用户上下文特征(自治系统号、服务供应商、区域拓扑)加权融合预测结果。

4. 根据权利要求1所述的一种流量特征自适应的QoS智能预测调整方法,其特征在于,所述资源优化模型的构建包括:

将数据分组服务过程建模为M/M/1排队系统,定义信道质量与QoS流需求的约束关系;

通过深度强化学习(DQN)离线训练资源分配策略,在线部署时根据实时流量预测值生成带宽分配比例及丢包优先级阈值。

5. 根据权利要求1所述的一种流量特征自适应的QoS智能预测调整方法,其特征在于,所述硬件加速层的执行包括:

将流量分类标记结果映射至多队列FIFO芯片的子队列,各子队列独立配置存储深度及几乎满/空偏移值;

通过微码比例控制算法按QoS优先级从高到低次序调度报文,延迟敏感型数据流分配至低延迟队列。

6. 根据权利要求2所述的一种流量特征自适应的QoS智能预测调整方法,其特征在于,所述自适应特征规则库的更新包括:

周期采集恶意流量特征样本,通过随机森林模型生成新规则;

对冗余特征属性进行相似度计算,若权重差值低于阈值则合并特征,动态压缩规则库规模。

7. 根据权利要求3所述的一种流量特征自适应的QoS智能预测调整方法,其特征在于,所述用户上下文特征的编码包括:

对用户ID、服务ID、区域编号进行One-hot编码并映射为稠密向量;

通过自注意力机制计算上下文特征间的关系权重,生成归一化交互特征矩阵。

8.根据权利要求4所述的一种流量特征自适应的QoS智能预测调整方法,其特征在于,所述资源分配策略的在线优化包括:

当实时流量超过带宽限制时,按QoS优先级由低至高依次计算丢包比例,释放冗余流量;

对临界状态流量采用微码比例控制算法,按(发送流量s:丢弃流量d)比例分段补偿余数。

9.根据权利要求1所述的一种流量特征自适应的QoS智能预测调整方法,其特征在于,还包括自适应反馈闭环:

监测QoS执行后的网络拥塞指标及用户设备延迟数据;

当预测误差超过阈值时,触发特征规则库重训练及长短期预测模型参数更新。

一种流量特征自适应的QoS智能预测调整方法

技术领域

[0001] 本发明涉及网络服务质量 (QoS) 管理技术,具体涉及一种基于流量特征自适应与智能预测的QoS动态调整方法,适用于智能网络流量控制组网、高性能组网等实时性网络场景。

背景技术

[0002] 近年来,QoS技术前沿呈现三大革新方向:

[0003] 1.细粒度控制与动态自适应;

[0004] 2.智能预测驱动的资源预分配;

[0005] 3.协议层与硬件加速融合;

[0006] 但现有技术或侧重静态规则(浪潮云)、或偏重预测算法(火山引擎),尚未形成“特征感知→预测→决策→硬件执行→反馈优化”的全闭环自适应体系,尤其缺乏:

[0007] 高频/低频流量分量的联合预测架构;

[0008] 强化学习与NPU硬件卸载的实时联动机制;

[0009] 基于预测误差触发的在线模型迭代能力。

发明内容

[0010] 基于此,本发明的目的是提供一种流量特征自适应的QoS智能预测调整方法,以解决上述背景技术中提出的技术问题。

[0011] 为实现上述目的,本发明提供如下技术方案:

[0012] 一种流量特征自适应的QoS智能预测调整方法,包括以下步骤:

[0013] 1.实时采集网络数据流,根据协议、端口号、应用特征及用户行为数据对流量进行动态分类与标记,生成多维特征向量;

[0014] 2.基于长短期预测融合模型处理所述多维特征向量:将历史QoS参数、网络状态信息及用户设备行为数据按时间序列分层,分离高频波动分量与低频趋势分量,分别输入LSTM短期预测模块和周期趋势分析模块,输出未来预设时间段内的QoS预测参数;

[0015] 3.根据QoS预测参数构建资源优化模型,以最小化分组平均时延为目标,通过强化学习求解离散空间下的资源预分配方案,动态调整带宽分配及优先级策略;

[0016] 4.通过硬件加速层执行资源预分配方案:利用NPU对流量识别、限速及优先级队列进行硬件卸载,实时输出QoS调整指令至网络设备。

[0017] 作为本技术方案中优选的,所述步骤1中的动态分类与标记包括:

[0018] 提取流量数据的协议类型、源/目的端口号、数据包大小分布特征;

[0019] 关联用户行为特征,包括访问频率、地理位置活跃度及历史异常行为标签;

[0020] 基于对称不确定性算法筛选与QoS需求强相关的特征属性,构建自适应特征规则库。

[0021] 作为本技术方案中优选的,所述长短期预测融合模型的处理包括:

- [0022] 高频波动分量输入LSTM网络,学习短期突发流量特征;
- [0023] 低频趋势分量通过核函数岭回归模型分析周期性规律,结合用户上下文特征(自治系统号、服务供应商、区域拓扑)加权融合预测结果。
- [0024] 作为本技术方案中优选的,所述资源优化模型的构建包括:
- [0025] 将数据分组服务过程建模为M/M/1排队系统,定义信道质量与QoS流需求的约束关系;
- [0026] 通过深度强化学习(DQN)离线训练资源分配策略,在线部署时根据实时流量预测值生成带宽分配比例及丢包优先级阈值。
- [0027] 作为本技术方案中优选的,所述硬件加速层的执行包括:
- [0028] 将流量分类标记结果映射至多队列FIFO芯片的子队列,各子队列独立配置存储深度及几乎满/空偏移值;
- [0029] 通过微码比例控制算法按QoS优先级从高到低次序调度报文,延迟敏感型数据流分配至低延迟队列。
- [0030] 作为本技术方案中优选的,所述自适应特征规则库的更新包括:
- [0031] 周期采集恶意流量特征样本,通过随机森林模型生成新规则;
- [0032] 对冗余特征属性进行相似度计算,若权重差值低于阈值则合并特征,动态压缩规则库规模。
- [0033] 作为本技术方案中优选的,所述用户上下文特征的编码包括:
- [0034] 对用户ID、服务ID、区域编号进行One-hot编码并映射为稠密向量;
- [0035] 通过自注意力机制计算上下文特征间的关系权重,生成归一化交互特征矩阵。
- [0036] 作为本技术方案中优选的,所述资源分配策略的在线优化包括:
- [0037] 当实时流量超过带宽限制时,按QoS优先级由低至高依次计算丢包比例,释放冗余流量;
- [0038] 对临界状态流量采用微码比例控制算法,按(发送流量s:丢弃流量d)比例分段补偿余数。
- [0039] 作为本技术方案中优选的,还包括自适应反馈闭环:
- [0040] 监测QoS执行后的网络拥塞指标及用户设备延迟数据;
- [0041] 当预测误差超过阈值时,触发特征规则库重训练及长短期预测模型参数更新。
- [0042] 综上所述,本发明主要具有以下有益效果:
- [0043] 1.实现全闭环自适应:通过构建特征感知→预测→决策→硬件执行→反馈优化的全链路体系,突破静态规则与纯算法方案的局限性,动态响应时延有效降低;
- [0044] 2.多频流量精准预测:采用高频/低频联合预测架构,结合小波分解与LSTM双通道处理,预测误差降低;
- [0045] 3.硬件协同加速:基于强化学习决策引擎与NPU硬件卸载的实时联动,QoS策略执行延迟从软件方案上得到优化;
- [0046] 4.在线迭代优化:通过预测误差触发模型更新,快速完成参数调整,支持突发流量下最大限度的SLA保障。

附图说明

- [0047] 图1为本发明的方法流程图；
[0048] 图2为本发明的动态分类与标记模块流程图；
[0049] 图3为本发明的预测融合处理模块架构图；
[0050] 图4为本发明的资源优化决策模块架构图；
[0051] 图5为本发明的硬件加速执行模块架构图；
[0052] 图6为本发明的系统分层架构图；
[0053] 图7为本发明的优先级调度模块架构图；
[0054] 图8为本发明的反馈闭环模块架构图；

具体实施方式

[0055] 下面将结合本发明实施例中的附图,对本发明实施例中的技术方案进行清楚、完整地描述。下面通过参考附图描述的实施例是示例性的,仅用于解释本发明,而不能理解为对本发明的限制。

[0056] 下面根据本发明的整体结构,对其实施例进行说明。

[0057] 如图1-8所示,本实施中提供了一种流量特征自适应的QoS智能预测调整方法,包括以下步骤:

[0058] 步骤1.实时采集网络数据流,根据协议、端口号、应用特征及用户行为数据对流量进行动态分类与标记,生成多维特征向量;

[0059] 步骤2.基于长短期预测融合模型处理所述多维特征向量:将历史QoS参数、网络状态信息及用户设备行为数据按时间序列分层,分离高频波动分量与低频趋势分量,分别输入LSTM短期预测模块和周期趋势分析模块,输出未来预设时间段内的QoS预测参数;

[0060] 步骤3.根据QoS预测参数构建资源优化模型,以最小化分组平均时延为目标,通过强化学习求解离散空间下的资源预分配方案,动态调整带宽分配及优先级策略;

[0061] 步骤4.通过硬件加速层执行资源预分配方案:利用NPU对流量识别、限速及优先级队列进行硬件卸载,实时输出QoS调整指令至网络设备。

[0062] 所述步骤1中的动态分类与标记包括:

[0063] 提取流量数据的协议类型、源/目的端口号、数据包大小分布特征;

[0064] 关联用户行为特征,包括访问频率、地理位置活跃度及历史异常行为标签;

[0065] 基于对称不确定性算法筛选与QoS需求强相关的特征属性,构建自适应特征规则库。

[0066] 本实施例中,流量动态分类与特征提取方式如下:

[0067] 1.数据采集:

[0068] 在智能网络流量控制组网或高性能组网架构中,例如网络基站边缘服务器部署轻量化探针(基于DPDK框架实现零拷贝抓包),实时捕获以下四维流量特征:

[0069] 1.1.协议层特征:解析IP报文头部获取协议类型(TCP/UDP/ICMP/QUIC),提取传输层源/目的端口号组合(如443-5001标识HTTPS视频流);

[0070] 1.2.数据包统计特征:计算滑动窗口内数据包大小方差(窗口大小=100包,方差>8000字节判定为视频流),统计单位时间报文到达间隔抖动(标准偏差>5ms触发突发流量标

记)；

[0071] 1.3.用户行为特征:关联用户历史数据库,加载地理位置活跃度指数(如移动速度>30km/h触发车载场景标记),注入历史异常行为标签(如DDoS攻击源IP库匹配)；

[0072] 1.4.网络环境特征:采集无线信道质量指示(CQI)及基站负载率(>80%触发拥塞预警)；

[0073] 2.自适应规则库构建：

[0074] 采用对称不确定性(Symmetric Uncertainty)算法进行特征筛选：

[0075] $SU(X,Y) = 2 \times I(X;Y) / (H(X) + H(Y))$ $SU(X,Y) = 2 \times H(X) / (H(X) + H(Y))$

[0076] 其中 $I(X;Y)$ 为特征X与QoS需求Y的互信息, $H(X)$ 为特征信息熵。

[0077] 3.筛选机制：

[0078] 设定SU阈值=0.65(经ROC曲线分析确定)

[0079] 高关联特征示例：

[0080] 视频流场景:包大小方差(SU=0.78)

[0081] 工业控制场景:报文到达间隔抖动(SU=0.82)

[0082] 4.规则库更新：

[0083] 每2小时注入新型威胁样本(如基于Spirent TestCenter生成的区块链节点加密计算交互流量),通过随机森林模型增量训练生成新规则集(树深度=10,特征袋采样率=0.8)。

[0084] 所述长短期预测融合模型的处理包括：

[0085] 高频波动分量输入LSTM网络,学习短期突发流量特征；

[0086] 低频趋势分量通过核函数岭回归模型分析周期性规律,结合用户上下文特征(自治系统号、服务供应商、区域拓扑)加权融合预测结果。

[0087] 所述用户上下文特征的编码包括：

[0088] 对用户ID、服务ID、区域编号进行One-hot编码并映射为稠密向量；

[0089] 通过自注意力机制计算上下文特征间的关系权重,生成归一化交互特征矩阵。

[0090] 本实施例中,长短期预测融合模型如下：

[0091] 1.频谱分离处理：

[0092] 对输入流量时序 $T(t)$ 进行小波分解：

[0093] $T(t) = A_{low}(t) + D_{high}(t)$ $T(t) = A_{low}(t) + D_{high}(t)$

[0094] 1.1低频分量 $A_{low}(t)$:输入周期趋势分析模块

[0095] 采用核函数岭回归(Kernel Ridge Regression)预测周期规律：

[0096] $y = K(X, X_{train}) (K(X_{train}, X_{train}) + \lambda I)^{-1} y_{train}$ $y = K(X, X_{train}) (K(X_{train}, X_{train}) + \lambda I)^{-1} y_{train}$

[0097] 其中高斯核 $K(x_i, x_j) = \exp(-\frac{|x_i - x_j|^2}{2\sigma^2})$, $\sigma = 0.5$ 。

[0098] 1.2高频分量 $D_{high}(t)$:输入LSTM网络网络结构:3层LSTM(128单元)+Dropout(0.2),输入窗口=50步长。

[0099] 2.上下文特征融合：

[0100] 2.1.特征编码与加权机制：

[0101] 特征向量化预处理:将用户标识(User ID)、服务编号(Service ID)、自治系统号(AS Number)等离散特征进行独热编码(One-hot Encoding),生成稀疏二值向量,通过嵌入层(Embedding Layer)将稀疏向量映射为128维稠密特征向量,消除维度灾难;

[0102] 2.2.自注意力权重计算:构建查询矩阵(Query Matrix)、键矩阵(Key Matrix)、值矩阵(Value Matrix)三组参数化向量: $Q=W_q \cdot E, K=W_k \cdot E, V=W_v \cdot E$;

[0103] 其中E为嵌入特征矩阵, $W_q/W_k/W_v$ 为可训练权重矩阵;

[0104] 2.3.计算特征间关联权重:

[0105] $\text{Attention}(Q, K, V) = \text{softmax}(\text{dk} \cdot QKT) V$

[0106] 其中 d_k 为键向量维度(设定为64), $\sqrt{d_k}$ 用于控制梯度稳定性;

[0107] 2.4.归一化处理:通过softmax函数将关联权重压缩至[0,1]区间,生成概率分布;

[0108] 2.5.加权特征融合:将归一化权重与原始特征向量进行哈达玛积(Hadamard Product):

[0109] $F_{\text{fused}} = \sum_i \alpha_i V_i, F_{\text{fused}} = \sum_i \alpha_i \odot V_i$

[0110] 其中 α_i 为第i个特征的注意力权重, $\odot$ 表示逐元素乘法;

[0111] 输出维度统一的交互特征矩阵(尺寸: $m \times 128$,m为用户数)。

[0112] 所述资源优化模型的构建包括:

[0113] 将数据分组服务过程建模为M/M/1排队系统,定义信道质量与QoS流需求的约束关系;

[0114] 通过深度强化学习(DQN)离线训练资源分配策略,在线部署时根据实时流量预测值生成带宽分配比例及丢包优先级阈值。

[0115] 所述硬件加速层的执行包括:

[0116] 将流量分类标记结果映射至多队列FIFO芯片的子队列,各子队列独立配置存储深度及几乎满/空偏移值;

[0117] 通过微码比例控制算法按QoS优先级从高到低次序调度报文,延迟敏感型数据流分配至低延迟队列。

[0118] 所述自适应特征规则库的更新包括:

[0119] 周期采集恶意流量特征样本,通过随机森林模型生成新规则;

[0120] 对冗余特征属性进行相似度计算,若权重差值低于阈值则合并特征,动态压缩规则库规模。

[0121] 所述资源分配策略的在线优化包括:

[0122] 当实时流量超过带宽限制时,按QoS优先级由低至高依次计算丢包比例,释放冗余流量;

[0123] 对临界状态流量采用微码比例控制算法,按(发送流量s:丢弃流量d)比例分段补偿余数。

[0124] 本实施例中,资源预分配与硬件加速如下:

[0125] 1.强化学习决策:

[0126] 建模为马尔可夫决策过程(MDP):

[0127] 状态 s_t :当前带宽利用率+QoS预测参数;

- [0128] 动作 a_t : {增加队列A带宽5%,降低队列B优先级,...};
- [0129] 奖励 r_t : $r_t = -(\text{平均时延} + 0.3 \times \text{丢包率})$;
- [0130] 使用DQN算法离线训练(ϵ -greedy策略, $\gamma = 0.9$),在线推理耗时 $< 2\text{ms}$ 。
- [0131] 2.微码比例控制:
- [0132] 2.1带宽超限时的动态丢弃策略:
- [0133] 2.1.1.优先级排序与权重分配:
- [0134] 预设8级优先级队列(0级最高,7级最低),各队列配置权重系数 w_i ($i = 0, 7$),满足 $\sum w_i = 1$;
- [0135] 权重系数与业务类型强相关(如下列表1内容):
- [0136]
- | 优先级 | 业务类型 | 权重 w_i |
|-----|--------|----------|
| 0 | 工业控制指令 | 0.35 |
| 1 | 实时视频 | 0.25 |
| ... | ... | ... |
| 7 | 软件更新 | 0.02 |
- [0137] 2.1.2.丢弃比例计算模型:
- [0138] 当实时流量 L_{current} 超过带宽上限 L_{max} 时:
- [0139] 计算总超限流量: $\Delta L = L_{\text{current}} - L_{\text{max}}$;
- [0140] 按优先级从低到高(7 $\rightarrow$ 0)逐队列计算丢弃量:
- [0141] $D_i = \min(\Delta L \times w_i, Q_i^{\text{len}})$ $D_i = \min(\Delta L \times w_i, Q_i^{\text{len}})$
- [0142] 其中 Q_i^{len} 为第 i 级队列当前积压报文数;
- [0143] 动态更新剩余超限量: $\Delta L = \Delta L - D_i$;
- [0144] 2.1.3.临界状态补偿机制:
- [0145] 若按权重分配后仍存在余量 $\Delta L_{\text{residual}} > 0$:
- [0146] 分段补偿原则:
- [0147] 余量 $\Delta L_{\text{residual}} \leq 5\% L_{\text{max}}$ 时:由最低优先级队列(7级)承担全部丢弃;
- [0148] 余量 $\Delta L_{\text{residual}} > 5\% L_{\text{max}}$ 时:按($S_i : D_i$) = (3:1)比例对次低优先级队列(6级)执行发送-丢弃混合调度;
- [0149] 其中, S_i :正常发送报文数, D_i :额外丢弃报文数;
- [0150] 2.2硬件执行流程:
- [0151] 2.2.1.NPU微码逻辑:
- [0152] 在可编程网络芯片(如Intel Tofino)中部署微指令集:
- [0153] 周期监测硬件队列计数寄存器(每 $10\mu\text{s}$ 采样);
- [0154] 触发条件:当 $\text{queue_total_count} > \text{threshold}_{\text{max}}$ 时启动丢弃计算,并行执行丢弃操作,具体如下:
- [0155] 通过队列管理单元(QMU)直接操作报文描述符环;
- [0156] 对目标队列注入drop_flag标记(不影响其他队列转发);
- [0157] 时延控制保障:
- [0158] 计算-执行全链路延迟 $\leq 0.8\mu\text{s}$ (实测数据);

- [0159] 确保高优先级队列不受低优先级丢弃操作干扰；
- [0160] 3.硬件加速执行：
- [0161] 在Intel Tofino芯片实现：
- [0162] 流量分类结果映射至8个硬件队列(FIFO深度可配置)；
- [0163] 高优先级队列设置almost_empty_offset=10%，触发提前调度。
- [0164] 该方法还包括自适应反馈闭环：
- [0165] 监测QoS执行后的网络拥塞指标及用户设备延迟数据；
- [0166] 当预测误差超过阈值时，触发特征规则库重训练及长短期预测模型参数更新。
- [0167] 本实施例中，自适应反馈闭环如下：
- [0168] 1.监测指标：

[0169] 核心指标：预测误差率 $E = \frac{|QoS_{pred} - QoS_{real}|}{QoS_{real}}$

[0170] 辅助指标：用户设备RTT波动方差；

[0171] 2.触发重训练条件：

[0172] 当连续3个周期 $E > 10\%$ 时：

[0173] 更新特征规则库：注入最新DDoS攻击样本(如SYN Flood特征)；

[0174] 调整LSTM超参：学习率从0.001降至0.0005，窗口扩至100步长。

[0175] 本实施例中，通过在智能网络流量控制组网或高性能组网的网络中进行随机3次以上测试(对比传统SDN QoS方案)，基于OMNeT++6.0仿真平台，负载流量采用3GPP TR 38.901标准模型，取多组测试结果平均数值，且去除小数点部分，具体数据如下表2中对比所示；

[0176]

指标	传统方案	本发明	提升幅度
平均时延	28ms	9ms	67.8%
突发流量丢包率	15.2%	2.1%	86.2%
策略响应延迟	120ms	0.2ms	99.8%
带宽利用率	72%	89%	23.6%

[0177] 表2

[0178] 尽管已经示出和描述了本发明的实施例，但本具体实施例仅仅是对本发明的解释，其并不是对发明的限制，描述的具体特征、结构、材料或者特点可以在任何一个或多个实施例或示例中以合适的方式结合，本领域技术人员在阅读完本说明书后可在不脱离本发明的原理和宗旨的情况下，可以根据需要对实施例做出没有创造性贡献的修改、替换和变型等，但只要在本发明的权利要求范围内都受到专利法的保护。




图1




图2




图3




图4




图5




图6




图7




图8